



PHOENIX

Uso, arquitectura y controles operativos de un harness de agentes de IA local-first y agnóstico de proveedor.

Tesis. PHOENIX convierte un runtime extensible en una superficie operable y auditable: compone capacidades como plugins, conserva la continuidad de sesión localmente y mantiene separadas las credenciales, los proveedores y las políticas de ejecución.

Audiencia

técnica

Formato

brief de 5 páginas

Fecha

28 agosto 2026

Una sesión, varias capacidades coordinadas

PHOENIX coloca la configuración y la seguridad cerca del usuario, sin ocultar los límites de cada proveedor.

01

Elegir proveedor

OpenRouter se configura desde Settings → Models; ChatGPT/Codex usa su plano nativo de cuenta.

02

Componer sesión

Un perfil apila bundles y parches para decidir qué agentes, herramientas y políticas entran al runtime.

03

Ejecutar y conservar

La sesión registra eventos durables para que el historial local pueda proyectarse, reanudarse y auditarse.

FLUJO DE USO

Configurar

proveedor, modelo y credencial local



Seleccionar

perfil y composición de capacidades



Conversar

agente, herramientas y contexto



Persistir

eventos y continuidad

Separación de identidades

La autenticación de API de OpenAI no se mezcla con la suscripción de ChatGPT. El puente nativo de Codex gestiona el inicio de sesión y la renovación OAuth; PHOENIX no pide la contraseña de ChatGPT ni persiste esos tokens.

Local-first con proveedor intercambiable

El proveedor, endpoint, catálogo y modelo activo se administran desde la UI. La continuidad de sesión permanece local por defecto y no se anuncia almacenamiento cloud sin una restauración comprobable.

“Model-visible means logged”: lo que llega a una petición de modelo debe poder reconstruirse desde el registro de sesión.

Composición antes que núcleo privilegiado

Los plugins aportan servicios, eventos y efectos reversibles a un contexto compartido.

Composición del runtime

Perfil · bundles ordenados

Patch del perfil · configuración

Patch del home · overlays explícitos

Runtime PHOENIX · plugins, servicios y herramientas

Fallback textual: las capas se aplican sobre una lista vacía en el orden del perfil, el parche del perfil, el parche del home y cualquier overlay `--patch`.

PAQUETES NÚCLEO

ÁREA	RESPONSABILIDAD
Session	Registro append-only y almacenamiento en memoria.
System prompt	Ensamblado de secciones y esquemas de herramientas.
Tools	Registro acotado y pipeline de ejecución guardado.
Agent / loop	Interfaz de agente y driver por defecto.
LLM	Vocabulario de mensajes, streams y seam de adaptadores.

SEAMS DE CAPACIDAD

Definición · proveedor · consumidor

Una capacidad completa declara su interfaz, implementa el proveedor y expone un consumidor, con frecuencia una herramienta orientada al modelo.

Eventos como extensión

Los eventos de sesión conservan hechos; los eventos de agente y de capacidad permiten observar o interceptar trabajo vivo sin importar el loop.

HARDNESS

Indexa capacidades y enruta modalidades; no reemplaza los registros de herramientas o skills ni se convierte en autoridad de ejecución.

Controles explícitos, límites visibles

La confianza se describe con la protección disponible y con el límite que todavía aplica.

CONTROL	QUÉ PROTEGE	EVIDENCIA DOCUMENTADA	LÍMITE DECLARADO
Credenciales separadas	Evita mezclar API keys con OAuth de ChatGPT/Codex.	documentado Plano nativo de Codex.	No convierte la credencial en permiso universal.
Sesión local durable	Historial, replay y continuidad sin subirlo por defecto.	documentado Registro local.	Backup cloud futuro requiere opt-in, cifrado y restauración real.
Runner Windows	Tokens restringidos y ACL para comandos nativos.	condicionado Gate en kernel Windows.	No promete aislamiento de red, invisibilidad de procesos ni protección ante todo hard-link.
Actualización estable	Fast-forward limpio, checkpoint y rollback ante fallo.	documentado Canal `origin/main`.	Worktrees sucios y ramas de desarrollo no se sobrescriben.
Full access	Permite operar fuera de la cerca de archivos.	limite Política `never`.	`danger-full-access` no es un sandbox ni añade una segunda aprobación.
Seguridad del proyecto	Canal privado para vulnerabilidades con contexto reproducible.	documentado GitHub private reporting.	No incluir claves, grants OAuth, sesiones ni datos personales.

Principio operativo

Una capacidad no se considera disponible solo por aparecer en un índice: las rutas `have` y `route` requieren evidencia de verificación actual.

Qué no se promete

No hay respaldo cloud anunciado hasta que existan recibos remotos y una prueba de restauración para la misma revisión.

De checkout a runtime verificable

La operación combina instalación reproducible, checks de proyecto y una postura de desarrollo activo.

INSTALACIÓN WINDOWS

Bootstrap dedicado

El instalador crea un checkout gestionado, instala dependencias, construye la revisión exacta y crea el acceso directo **PHOENIX HARDNESS**.

```
irm ../install-phoenix.ps1 | iex
```

IDE

VS Code y Cursor

El paquete VSIX inicia el runtime local y abre la Web UI sin leer credenciales de modelos.

```
pnpm run package:vscode
```

CHECKS RELEVANTES

- **TypeScript:** `pnpm run typecheck`
- **Build completo:** `pnpm run build`
- **Documentación:** `pnpm run doc-sync`
- **Website:** `pnpm run website:build`
- **Pruebas unitarias:** `pnpm run test`
- **Higiene:** `pnpm run hygiene`
- **Gate Windows:** `pnpm run check:ci:windows-complete`
- **Soporte:** Issues y Discussions del repositorio.

Lectura de estado

ESTADO	INTERPRETACIÓN	PRÓXIMO CRITERIO
en desarrollo activo	PHOENIX evoluciona por capas aisladas y verificables.	Conservar gates verdes en la revisión exacta.
condicionado	La seguridad Windows depende del kernel y del runner nativo.	Ejecutar el gate autoritativo en Windows real.
no anunciado	Backup cloud y release firmado no son promesas actuales.	Exigir recibo, restauración y certificado externo antes de promocionar.

Conclusión: PHOENIX es más útil cuando el usuario trata la selección de modelos, la composición de capacidades y los checks de confianza como parte de la misma operación.